

# Econometría I (EC402)

## Clase #15 - Análisis de Varianza y Predicción

Prof. Andrés M. Castaño

Ingeniería Comercial  
Universidad Católica del Norte  
Lunes 28 de octubre de 2013

# Análisis de varianza



$$\begin{aligned}STC &= SEC + SRC \\ \sum y_i^2 &= \sum \hat{y}_i^2 + \sum \hat{\mu}_i^2 \\ &= \hat{\beta}_2^2 \sum x_i^2 + \sum \hat{\mu}_i^2\end{aligned}$$

- El estudio de los componentes de la STC se conoce como el análisis de varianza.
- Asociado con cada uno de estos componentes está, sus respectivos grados de libertad. STC (n-1) gl, SRC (n-2) gl, SEC (1) gl.

# Tabla análisis de varianza

**TABLA 5.3** TABLA ANOVA PARA EL MODELO DE REGRESIÓN CON DOS VARIABLES

Fuente de variación	SC*	g de l	SPC†
Debido a la regresión (SEC)	$\sum y_i^2 = \hat{\beta}_2^2 \sum x_i^2$	1	$\frac{\hat{\beta}_2^2 \sum x_i^2}{\sum \hat{u}_i^2} = \hat{\sigma}^2$
Debido a los residuos (SRC)	$\sum \hat{u}_i^2$	$n - 2$	
STC	$\sum y_i^2$	$n - 1$	

\* SC significa suma de cuadrados.

† Significa suma de promedio de cuadrados, la cual se obtiene dividiendo SC por el número de g de l.

## El estadístico F

- Si se satisface que  $\mu_i$  esté normalmente distribuida, y si  $H_0 : \beta_2 = 0$ , existe un estadístico F que satisface la distribución F, con 1 y n-2 gl.

•

$$\begin{aligned} F &= \frac{SPC(SEC)}{SPC(SRC)} \\ &= \frac{\hat{\beta}_2^2 \sum x_i^2}{\frac{\sum \hat{\mu}_i}{n-2}} \\ &= \frac{\hat{\beta}_2^2 \sum x_i^2}{\hat{\sigma}^2} \end{aligned}$$

## El estadístico F



$$E(\hat{\beta}_2^2 \sum x_i^2) = \sigma^2 + \beta_2^2 \sum x_i^2$$

y

$$E\left(\frac{\sum \hat{\mu}_i}{n-2}\right) = E(\hat{\sigma}^2) = \sigma^2$$

- Si  $\beta_2 = 0$ , entonces ambas expresiones proporcionan el mismo valor para  $\sigma^2$ . Una distribución T (con k gl) al cuadrado es una distribución F (1 : k) gl.
- Las pruebas T y F, proporcionan, dos formas alternas pero complementarias de testear  $H_0 : \beta_2 = 0$ .
- Cuando el análisis es de dos variables la prueba F es innecesaria, con más variables se pueden testear hipótesis globales.

# Aplicaciones del análisis de regresión: problema de predicción

- obtenido:

$$\hat{Y}_i = 24,4545 + 0,5091X_i$$

- Qué podemos hacer con esta regresión:
- 1  $\implies$  Predicción media: valor de la media condicional de Y correspondiente al valor de X (ejemplo  $X_0$ ).
- 2  $\implies$  Predicción individual: predicción de un valor individual Y, correspondiente a  $X_0$ .

# Predicción media

- Suponga que  $X_0 = 100$ , y deseamos saber  $E(Y | X_0 = 100)$ . Obteniedo:

$$\begin{aligned}\hat{Y}_0 &= \hat{\beta}_1 + \hat{\beta}_2 X_0 \\ &= 24,4545 + 0,5091(100) \\ &= 75,364\end{aligned}$$

- Dado que  $\hat{Y}_0$  es un estimador, puede ser diferente del verdadero valor  $\implies$  Error de predicción  $\implies$  debemos encontrar la distribución muestral de  $\hat{Y}_0$ .
- $Y_0$  se distribuye con media  $= (\beta_1 + \beta_2 X_0)$ , y
- $Var(\hat{Y}_0) = \sigma^2 \left( \frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum x_i^2} \right)$
- $t = \frac{\hat{Y}_0 - (\beta_1 + \beta_2 X_0)}{ee(\hat{Y}_0)}$

## Predicción media

- Intervalo de cofianza para el verdadero  $E(Y_0 | X_0)$

$$Pr(\beta_1 + \beta_2 X_0 - t_{\frac{\alpha}{2}} ee(\hat{Y}_0) \leq \beta_1 + \beta_2 X_0 \leq \beta_1 + \beta_2 X_0 + t_{\frac{\alpha}{2}} ee(\hat{Y}_0)) = 1 - \alpha$$



# Predicción media: Ejemplo...tabla 3.3 (Gujarati)

**TABLA 3.3** DATOS PRIMARIOS BASADOS EN LA TABLA 3.2

$Y_i$ (1)	$X_i$ (2)	$Y_i X_i$ (3)	$X_i^2$ (4)	$X_i =$ $X_i - \bar{X}$ (5)	$Y_i =$ $Y_i - \bar{Y}$ (6)	$x_i^2$ (7)	$x_i y_i$ (8)	$\hat{Y}_i$ (9)	$\hat{u}_i =$ $Y_i - \hat{Y}_i$ (10)	$\hat{Y}_i \hat{u}_i$ (11)
70	80	5 600	6 400	-90	-41	8 100	3 690	65.1818	4.8181	314.0524
65	100	6 500	10 000	-70	-46	4 900	3 220	75.3636	-10.3636	-781.0382
90	120	10 800	14 400	-50	-21	2 500	1 050	85.5454	4.4545	381.0620
95	140	13 300	19 600	-30	-16	900	480	95.7272	-0.7272	-69.6128
110	160	17 600	25 600	-10	-1	100	10	105.9090	4.0909	433.2631
115	180	20 700	32 400	10	4	100	40	116.0909	-1.0909	-126.6434
120	200	24 000	40 000	30	9	900	270	125.2727	-6.2727	-792.0708
140	220	30 800	48 400	50	29	2 500	1 450	136.4545	3.5454	483.7858
155	240	37 200	57 600	70	44	4 900	3 080	145.6363	8.3636	1 226.4073
150	260	39 000	67 600	90	39	8 100	3 510	156.8181	-6.8181	-1 069.2014
Suma 1 110	1 700	205 500	322 000	0	0	33 000	16 800	1 109.9995	0	0.0040
Media 111	170	nc	nc	0	0	nc	nc	110.0	0	0.0
$\hat{\beta}_2 = \frac{\sum x_i y_i}{\sum x_i^2} = 16\,800/33\,000 = 0.5091$										
$\hat{\beta}_1 = \bar{Y} - \hat{\beta}_2 \bar{X} = 111 - 0.5091(170) = 24.4545$										

## Cálculos ejemplo...

- obtenido:

$$\begin{aligned}\hat{Y}_0 &= \hat{\beta}_1 + \hat{\beta}_2 X_0 \\ &= 24,4545 + 0,5091(100) \\ &= 75,364\end{aligned}$$

- Con media  $= (\beta_1 + \beta_2 X_0)$ .
- $Var(\hat{Y}_0) = 42,159\left(\frac{1}{10} + \frac{(100-170)^2}{33000}\right) = 10,4759$

## Cálculos ejemplo...

- Intervalo de confianza al 95 % de confianza para el verdadero

$$E(Y | X_0) = \beta_1 + \beta_2 X_0 :$$

$$75,3645 - 2,306(3,2366) \leq E(Y_0 | X = 100) \leq 75,3645 + 2,306(3,2366)$$

$$(67,9010 \leq E(Y_0 | X = 100) \leq 82,8381) = 1 - \alpha$$

- Interpretación: En muestreo repetido dado  $X_0 = 100$ , en 95 de cada 100 intervalos como el anterior estará incluido el verdadero valor medio de  $Y_0$ .

## Predicción individual.....

- Si el interés está en predecir un valor individual  $Y$ ,  $Y_0$  correspondiente a un valor dado de  $X$  ( $X_0$ ), el mejor estimador lineal insesgado de  $Y_0$  esta dado por:

$$= (\beta_1 + \beta_2 X_0)$$

- $$Var(Y_0 - \hat{Y}_0) = E(Y_0 - \hat{Y}_0)^2 = \sigma^2 \left( 1 + \frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum x_i^2} \right)$$

- $$t = \frac{Y_0 - \hat{Y}_0}{ee(Y_0 - \hat{Y}_0)}$$

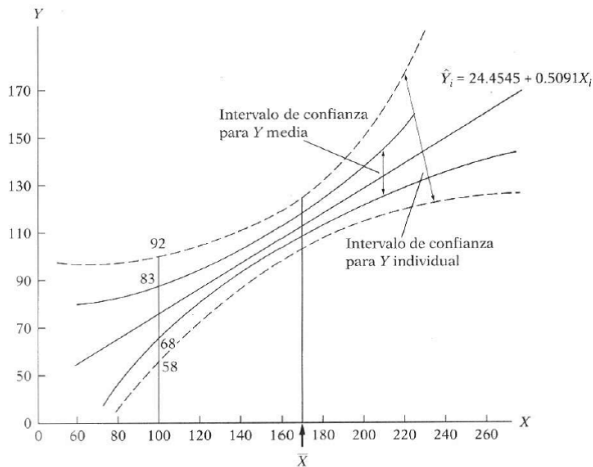
- Con el mismo ejemplo, hallar el intervalo de confianza para la predicción individual, debería darles:

$$(58,6345 \leq Y_0 \mid X_0 = 100 \leq 92,0945)$$

## Predicción individual.....

- Evaluar lo siguiente: ¿Es posible decir con una confianza del 95 % que el consumo de una familia será de 110 (miles) si el ingreso es 180 (miles)?

# Comparación predicción media vs predicción individual



Intervalos (bandas) de confianza para  $Y$  media y para valores individuales de  $Y$ .

## Volvamos a una salida de regresión

$$\begin{array}{llll} \hat{Y}_i = 24.4545 & + & 0.5091X_i & \\ ee = (6.4138) & & (0.0357) & r^2 = 0.9621 \\ t = (3.8128) & & (14.2605) & \text{g de l} = 8 \\ p = (0.002571) & & (0.000000289) & F_{1,8} = 202.87 \end{array}$$

# Qué hacer después de obtener la salida


- Signo de los coeficientes
- Significancia de los coeficientes
- Bonda de ajuste
- Estudiar el cumplimiento de los supuestos



# Prueba de normalidad

- Histograma de los residuos
- Gráfica de probabilidad normal
- Prueba Jarque-Bera

# Histograma de residuos



Series: residuos

Muestra 1 55

Observaciones 55

Media  $-1.19 \times 10^{-14}$

Mediana 7.747849

Máximo 171.5859

Mínimo -153.7664

Desviación estándar 66.23382


Asimetría 0.119816

Curtosis 3.234473

Jarque-Bera 0.257585

Probabilidad 0.879156

# Gráfica de probabilidad normal



Promedio = -0.0000000  
Desv. estándar = 6.12166  
N = 10

$A^2 = 0.394$   
Valor  $p = 0.305$

# Prueba Jarque-Bera (JB)

- Prueba asintótica o de grandes muestras.
- Calcula la asimetría y la curtosis de los residuos.

- 

$$JB = n\left(\frac{S^2}{6} + \frac{(K - 3)^2}{24}\right)$$

n=tamaño de la muestra; S=coeficiente de asimetría;  
K=coeficiente de curtosis.